Documento de Diseño Técnico: Predicción de riesgo crediticio

Integrantes: Felipe Rubio, Ximena Soliz y Yasmin Bazán.
Asignatura: Gestión de datos para IA 001D
Profesora: Jazna Meza Hidalgo
Grupo: N°8
Fecha: 07/04/2026

Contenido

Contenido 1
Introducción 2
1. Descripción técnica del sistema 2
    1.1 Componentes técnicos del sistema 2
    1.2 Estructura general 2
    1.3 Tecnologías utilizadas 2
    1.4 Relación entre componentes 3
2. Diagrama técnico de la solución 3
3. Modelo de datos básico y diccionario 4
    3.1 Modelo de datos 4
    3.2 Diccionario de datos 4
4. README.md actualizado y versionado 6
Cierre 7

Introducción

Este documento tiene como objetivo describir de forma técnica y estructurada el sistema desarrollado por el equipo, orientado a la predicción del riesgo de impago en solicitudes de préstamo (Loan Default). Contiene los elementos necesarios para comprender, replicar y mantener la solución tecnológica, sirviendo como base técnica para la implementación del Pipeline Híbrido de Datos. A nivel metodológico, el diseño sigue un proceso de desarrollo basado en la planificación, es decir, que se establece una arquitectura clara antes de la implementación para garantizar la fiabilidad del sistema final.

1. Descripción técnica del sistema

1.1 Componentes técnicos del sistema

El sistema se compone de los siguientes módulos funcionales:

- **Script de ingesta de datos**, extrae los datos crudos desde el archivo **02_loan_datac.csv**
- **Script de limpieza de datos**, para manejar valores flotantes, nulos, duplicados, etc.
- **Script de transformación,** para procesar las variables y realizar la codificación matemática de variables cualitativas a cuantitativas y evaluar la correlación estadística.
- **Base de datos PostgreSQL,** para los datos procesados y ya estructurados.
- **Script de entrenamiento,** con Scikit-Learn.
- **Dashboard/Aplicación,** para que sea la interfaz gráfica.
- **Contenedor de despliegue (Docker),** entorno aislado que empaqueta la base de datos, los scripts y la visualización para su portabilidad.

1.2 Estructura general

La solución está estructurada de manera modular bajo un diseño arquitectónico de Pipeline Híbrido. Por lo que, se separa el procesamiento de datos del modelado predictivo y de la interfaz de usuario. Cada script tiene y cumple una función específica y secuencial, facilitando la mantenibilidad del código y su aislamiento de errores.

1.3 Tecnologías utilizadas

- **Editor / IDE**: Visual Studio Code + Antigravity AI (Asistente de desarrollo).
- **Lenguaje de Programación**: Python 3 (Machine Learning, procesamiento y modelado).
- **Control de versiones:** Git & GitHub (Colaboración y control de código).
- **Contenerización**: Docker (Entornos inmutables y gestión de dependencias).
- **Automatización (CI/CD)**: GitHub Actions (Orquestación de flujos de trabajo).
- **Base de Datos:** PostgreSQL (Base de datos relacional).
- **Despliegue / Hosting**: Render, plataforma cloud para el despliegue final de la solución.

1.4 Relación entre componentes

El flujo de ejecución de los scripts es en el siguiente orden: Ingesta → Limpieza → Transformación → Entrenamiento. Cada etapa depende de la salida de la anterior. El dataset limpio se guarda en PostgreSQL y se utiliza luego en el modelado y visualización.

2. Diagrama técnico de la solución

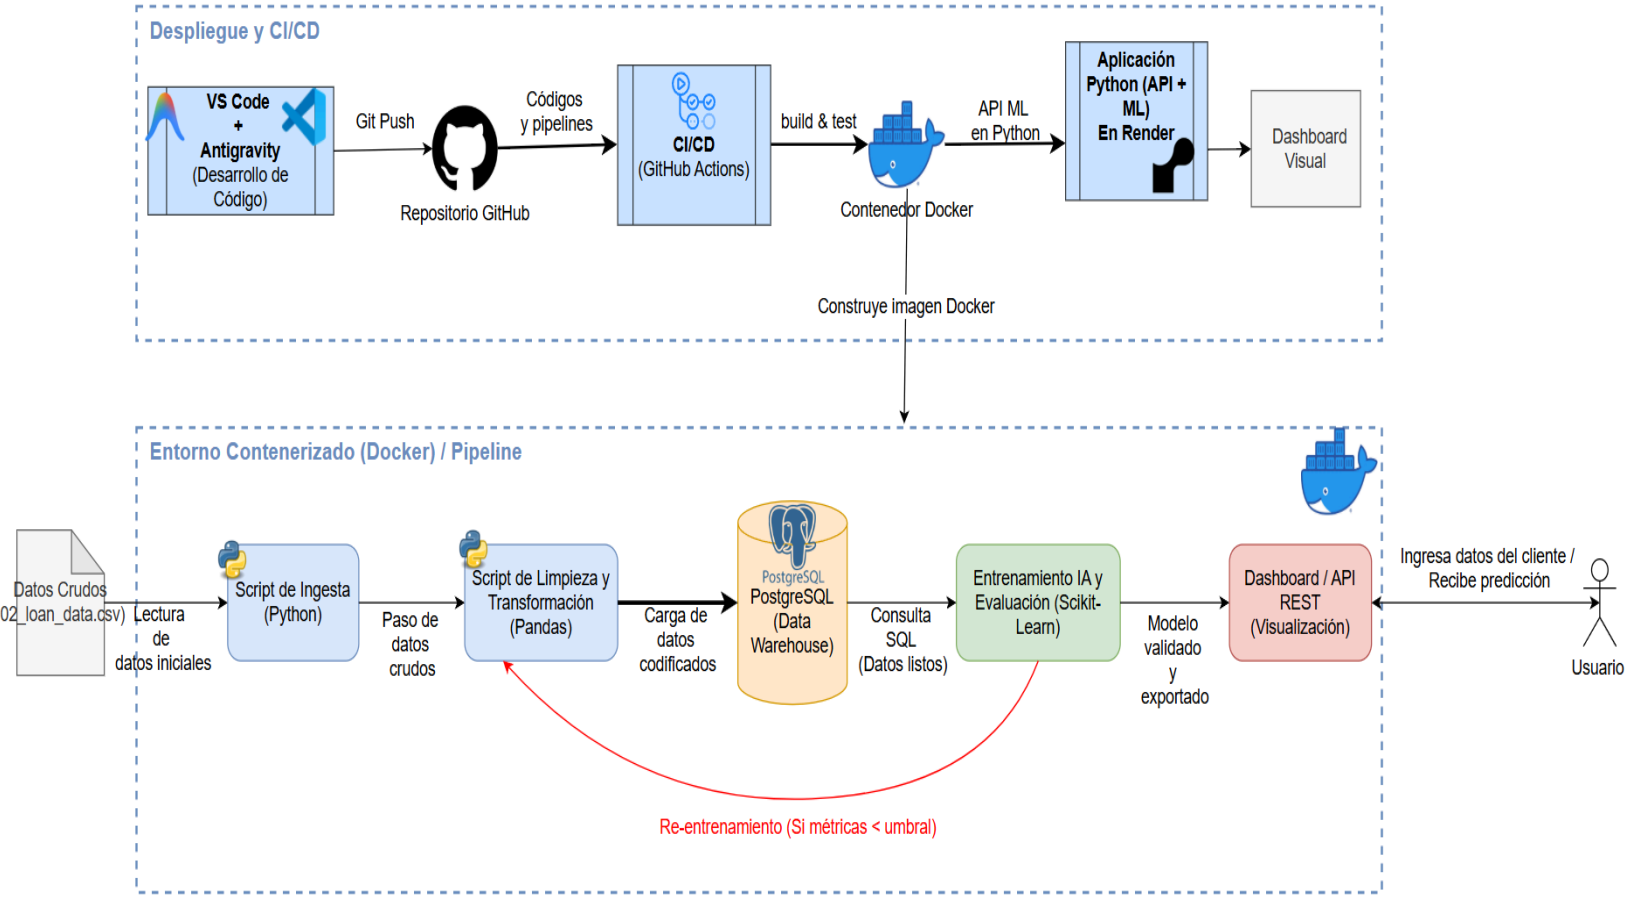

3. Modelo de datos básico y diccionario

3.1 Modelo de datos

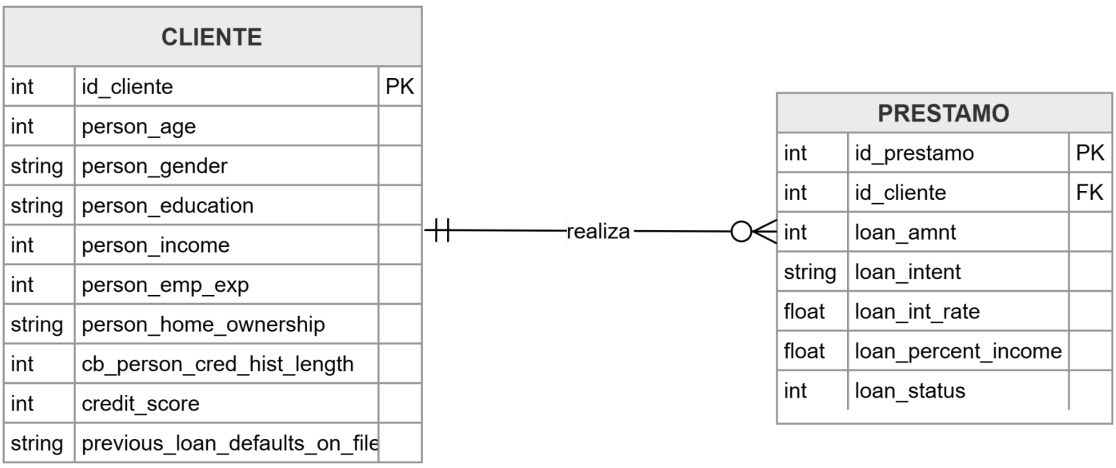

3.2 Diccionario de datos

Campo	Tipo de dato	Descripción	Valores esperados / restricciones	¿Obligatorio?
person_age	INT /float	Edad del solicitante medida en años.	>= 0	Sí
person_gender	String	Género del solicitante.	male / female	No
person_education	String	Nivel educativo del solicitante.	High School, Bachelor, Master, Associate, Doctorate	No

person_income	INT/float	Ingreso anual del solicitante	>= 0	Sí
person_emp_exp	INT	Años de experiencia laboral	>= 0	Sí
person_home_ownership	String	Situación de vivienda	RENT, OWN, MORTGAGE, OTHER	Sí
loan_amnt	INT/float	Monto del préstamo solicitado	>= 0	Sí
loan_intent	String	Propósito del préstamo	PERSONAL, EDUCATION, MEDICAL, VENTURE, DEBTCONSOLIDATION, HOMEIMPROVEMENT	No
loan_int_rate	Int/float	Tasa de interés asignada	Decimal >= 0	Sí
loan_percent_income	INT/float	Porcentaje del préstamo respecto al ingreso	Valor numérico decimal entre 0 y 1	Sí
cb_person_cred_hist_length	INT/float	Años de historial crediticio	>= 0	Sí
credit_score	INT	Puntuación crediticia del solicitante	>= 0	Sí
previous_loan_defaults_on_file	String	Defaults anteriores	Yes, No	Sí
loan_status	INT	Variable objetivo: 1 sí es default, 0 si es pagado	1, 0	Sí

4. README.md actualizado y versionado

Como parte integral de la arquitectura y el control de versiones, el proyecto cuenta con un archivo README_v1.md centralizado en el repositorio oficial de GitHub. Este documento actúa como el núcleo de información operativa y técnica, asegurando que la configuración, ejecución y despliegue del sistema predictivo de riesgo crediticio sean procesos transparentes y replicables.

Para garantizar un estándar de documentación profesional, el archivo se ha estructurado bajo los siguientes componentes clave:

- **Identificación y Contexto:**

  Define el nombre del proyecto, los integrantes del equipo y el objetivo general de predecir el estado de impago mediante Inteligencia Artificial.

- **Especificación del Stack Tecnológico:**

  Enumera y justifica las herramientas que componen el ecosistema, incluyendo el lenguaje Python, el Data Warehouse en PostgreSQL, y la infraestructura basada en Docker y Render.

- **Jerarquía de Archivos y Carpetas:**

  Detalla la organización lógica del repositorio, identificando la ubicación de los datos crudos, los scripts del pipeline (ingesta, limpieza, entrenamiento) y los archivos de configuración de infraestructura como Dockerfile y docker-compose.yml.

- **Guía de Despliegue y Ejecución:**

  Proporciona instrucciones técnicas paso a paso para clonar el repositorio, configurar variables de entorno mediante .env.example, y levantar el entorno contenerizado. Además, detalla el orden secuencial de ejecución de los scripts del Pipeline Híbrido.

- **Trazabilidad y Roadmap:**

  Incluye un enlace directo a la documentación técnica consolidada y un registro del estado actual del desarrollo (Roadmap V1), permitiendo visualizar el progreso desde la planificación hasta el despliegue final.

La implementación y versionamiento constante de este archivo garantiza que el diseño técnico se mantenga alineado con la ejecución práctica, facilitando la escalabilidad de la solución.

Cierre

En este documento se establece la arquitectura tecnológica y el ecosistema de herramientas que soportará nuestro sistema predictivo de riesgo crediticio. El diseño propuesto, basado en un modelo de Pipeline Híbrido, asegura una transición robusta y controlada desde la ingesta de datos crudos hasta la disponibilización del modelo de Inteligencia Artificial.

A nivel de infraestructura, la selección de nuestro stack tecnológico ha sido estratégica para garantizar la escalabilidad y la trazabilidad del proyecto. La centralización del almacenamiento estructurado en PostgreSQL actuará como un Data Warehouse confiable, asegurando que el modelo de clasificación desarrollado en Python se alimente exclusivamente de datos limpios, balanceados y libres de sesgos o redundancias matemáticas.

Asimismo, la integración de Docker para la contenerización garantiza la inmutabilidad del entorno, eliminando posibles problemas entre el desarrollo local y la nube. Acoplado a esto, la implementación de flujos CI/CD mediante GitHub Actions permitirá automatizar el despliegue hacia la plataforma Render, minimizando el error y acelerando las iteraciones durante la fase de evaluación del modelo.

En conclusión, este diseño técnico proporciona una base sólida, moderna y orientada a la nube. Con esta arquitectura formalmente definida y validada, el equipo cuenta con las herramientas técnicas necesarias para iniciar la fase de Desarrollo Técnico, comenzando con la programación de los scripts de ingesta y transformación de datos.